

MINI-PROJET DE MASTER / ALGORITHMES MÉTAHEURISTIQUES

Approximation neuronale et optimisation d'une décision thermique

Valeur, sensibilité et qualité de décision
sur un benchmark analytique

M2 en cours — Master

Modélisation mathématique et applications et apprentissages

RÉALISÉ PAR

Mhamed Halhoul

PROFESSEUR ENCADRANT :

Pr. Jamal Daoudi

Deux questions distinctes

Apprendre une fonction, puis choisir une durée physique

Apprentissage

Paramètres du réseau : $\theta \in \mathbb{R}^{49}$.

$$\min_{\theta} \mathcal{L}(\theta).$$

La perte est généralement non convexe.

Décision

Durée physique : $p \in [0.02, 0.20]$.

$$\min_p J_{\lambda}(p).$$

L'objectif physique est fortement convexe.

Association. L'erreur de sensibilité classe-t-elle mieux la mauvaise décision ?

Comparaison. La supervision valeurs et dérivées améliore-t-elle le score moyen, et sous quels coûts ?

À distinguer : convexité en p , apprentissage en θ et comparaison des méthodes.

Un oracle thermique analytique

Deux modes de l'équation de la chaleur ; variables sans dimension

$$T(p) = \frac{e^{-\pi^2 p}}{\sqrt{2}} + 0.2e^{-4\pi^2 p}, \quad J_\lambda(p) = T(p) + \lambda p.$$

Capteur $x = 1/4$ de $u_t = u_{xx}$, avec des bords homogènes.

$$J'_\lambda = T' + \lambda, \quad 0 < m = T''(b) \leq J''_\lambda.$$

Référence physique M0

$$\lambda_b = -T'(b) < \lambda_a = -T'(a).$$

$$p_{\text{ref}} = b \text{ si } \lambda \leq \lambda_b ; p_{\text{ref}} = a \text{ si } \lambda \geq \lambda_a.$$

Sinon : dichotomie sur l'unique racine intérieure.

Limite numérique : M0 est une référence flottante ; ses bornes restent conditionnelles.

Un réseau scalaire à 49 paramètres

Architecture tanh 1-16-1 ; dérivée par rapport à la durée physique

Normalisation et paramètres

$$z = \frac{2(p-a)}{b-a} - 1, \quad \alpha_N = \frac{100}{9}.$$

$$\theta = (w, b, v, d).$$

$$16 + 16 + 16 + 1 = 49.$$

$$c_{\text{out}} = 0, \quad s_{\text{out}} = 1.$$

Valeur et sensibilité

$$h_i = \tanh(w_i z + b_i).$$

$$\hat{T} = d + \sum_i v_i h_i.$$

$$\hat{T}'(p) = \alpha_N \sum_i v_i w_i (1 - h_i^2).$$

Point de vigilance : l'architecture n'impose ni monotonie ni convexité.

Apprendre les valeurs et les dérivées

Même architecture ; deux pertes avec des échelles fixées par l'oracle

M1 : valeurs seules

$$\mathcal{L}_1 = \frac{1}{n} \sum_j \frac{(\hat{T} - T)^2}{S_0^2}.$$

$$S_0 = T(a) - T(b) \simeq 0.57295.$$

M2 : valeurs et sensibilités

$$\mathcal{L}_2 = \mathcal{L}_1 + \frac{1}{n} \sum_j \frac{(\hat{T}' - T')^2}{S_1^2}.$$

$$S_1 = -T'(a) \simeq 9.31369.$$

Coefficient différentiel 1 ; aucun facteur 1/2 ; aucune régularisation.

Gradients analytiques des 49 paramètres.

Échelles fixes : aucune estimation de S_0 ou S_1 sur les sites diagnostiques.

Vingt initialisations appariées

Trois conditions ; 3000 mises à jour Adam ; snapshot 300 secondaire

Condition	Sites	n_T	$n_{T'}$	Coût si $q_1 = 1$
M1_16	16	16	0	16
M2_16	16	16	16	32
M1_32	32	32	0	32

Appariement. Mêmes paramètres initiaux pour les trois conditions d'une graine.

Adam full-batch. $\eta = 0.001$, $\beta_1 = 0.9$, $\beta_2 = 0.999$, $\epsilon = 10^{-8}$ hors racine ; compteur et moments conservés.

Diagnostic. 257 sites disjoints des sites d'apprentissage.

$q_1 = 1$ est une convention : un même coût de labels n'égale ni les sites ni le temps.

Des garanties sous hypothèses

Bornes classiques ; distinction entre théorie et contrôle flottant

Erreur uniforme

$$R \leq 2\varepsilon + \alpha_{\text{opt}}.$$

Erreur uniforme et défaut global d'optimisation majorés.

Une RMSE ne fournit pas ε .

Optimalité physique

$$|p - p^*| \leq r/m.$$

$$R \leq r^2/(2m).$$

r : résidu KKT physique, avec les signes adaptés aux frontières.

Décision neuronale : meilleur des 1025 candidats, sans raffinement.

Aucune convexité du réseau supposée.

Pas de certificat numérique : les erreurs flottantes totales ne sont pas majorées.

Une graine illustre la difficulté

Graine 20262001 ; étape 3000 ; trois modèles sauvegardés ; 257 sites





Illustration : graine 20262001, étape 3000, 257 sites diagnostiques

Pour cette graine : M2 réduit les RMSE, mais son score décisionnel est légèrement plus élevé. Ce n'est pas une moyenne.

Toutes les paires restent visibles

Vingt initialisations conservées ; deux comparaisons prévues




Étape 3000, $n = 20$ graines appariées, toutes conservées
 S est une différence de coût contre M0 flottant ; unités sans dimension

$$D = J_{\text{phys}}(\hat{p}) - J_{\text{phys}}(p_{\text{ref}}), \quad S = \frac{1}{3} \sum_{k \in \mathcal{I}} D_{\lambda_k}.$$

Score brut : moyenne des trois tâches intérieures, sans écrêtage ; référence flottante.

Un gain moyen dans ce benchmark

Différences appariées à l'étape 3000 ; intervalles bootstrap à 95 %



Étape 3000, $n = 20$ paires ; IC percentiles 95 %, $B = 2000$ tirages par blocs
M1_32 : égalité du coût de labels uniquement sous $q_1 = 1$

$M2_{16} - M1_{16}$

-0.01006

IC : $[-0.01460; -0.00557]$

$M2_{16} - M1_{32}$


-0.00940

IC : $[-0.01390; -0.00503]$

13 paires favorables sur 20 : gain moyen dans chaque comparaison, sans gain garanti pour toute graine.

Erreur et mauvaise décision

Panel principal : M1_16 à 3000 ; vingt points ; associations de rang



Panel principal : M1_16, étape 3000, $n = 20$ graines
 $\Delta\rho = 0.0068$, IC bootstrap 95 % $[-0.0568; 0.0791]$: inconclusif

Deux associations positives : l'IC de $\Delta\rho$ inclut zéro ; l'association supérieure des sensibilités reste inconclusive.

Une différence de corrélations incertaine

Bootstrap par blocs de graines ; $n = 20$; $B = 2000$

Statistique	Estimation	IC 95 %
ρ_{valeur}	0.9413	[0.8000; 0.9882]
ρ_{sens}	0.9481	[0.7925; 0.9958]
$\Delta\rho$	0.0068	[-0.0568; 0.0791]

Une matrice commune ; graines tirées avec remise ; blocs complets conservés.

Rangs moyens pour égalités exactes ; variable constante : non défini. IC percentile interpolé ; au moins 90 % de tirages définis.

Autres conditions, étape 300 et frontières : secondaires.

Portée des IC : pas de pooling et pas de garantie simultanée.

Deux conclusions, une portée limitée

Séparer la comparaison des méthodes de l'hypothèse d'association

Comparaison des méthodes

M2 améliore le score décisionnel moyen dans les deux comparaisons prévues, dans ce benchmark.

Hypothèse d'association

L'association supérieure des sensibilités reste **inconclusive**.

Limites. Un cas scalaire sans bruit ; vingt initialisations ; référence flottante ; protocole fixé après inspection du pilote.

Suite proposée. Transfert à un second cas physique, avec les coûts des valeurs et des dérivées mesurés. Cette extension reste non exécutée.

Aucune revendication : nouveauté d'algorithme, causalité ou supériorité générale.

Références et données traçables

Méthodes établies ; bibliographie complète dans le rapport

Czarnecki et al. *Sobolev Training for Neural Networks*. NIPS, 2017.

Yao et al. *Derivative-Informed Fourier Neural Operator: Universal Approximation and Applications to PDE-Constrained Optimization*. arXiv:2512.14086, 2025, révision 2026. Prépublication.

Alexandrov et al. *A trust-region framework for managing the use of approximation models in optimization*. 1998.

Elmachtoub et Grigas. *Smart Predict, then Optimize*. Management Science, 2022.

Lecture bibliographique partielle. Archives : résultats 3B/3C, paramètres, contextes et exports CSV.

Édition documentaire : aucun nouvel entraînement pour cette présentation.