

Approximation neuronale et optimisation d'une décision thermique

Valeur, sensibilité et qualité de décision
sur un benchmark analytique

Mhamed Halhoul

Faculté Polydisciplinaire de Larache

M2 en cours — Master

Modélisation mathématique et applications et apprentissages

Module : Algorithmes métaheuristiques

Enseignant du module : Pr. Jamal Daoudi

Apprentissage et décision physique

$$\theta \in \mathbb{R}^{49} : \min_{\theta} \mathcal{L}(\theta), \quad p \in [0.02, 0.20] : \min_p J_{\lambda}(p).$$

La convexité physique en p ne rend pas la perte convexe en θ .

- Association : l'erreur de sensibilité classe-t-elle mieux la mauvaise décision ?
- Comparaison : la supervision valeurs et dérivées améliore-t-elle le score moyen, sous quels coûts ?

Température et référence physique M0

$$T(p) = \frac{e^{-\pi^2 p}}{\sqrt{2}} + 0.2e^{-4\pi^2 p}, \quad J_\lambda(p) = T(p) + \lambda p.$$

Capteur $x = 1/4$ de $u_t = u_{xx}$, deux modes, bords homogènes. Toutes les variables sont sans dimension.

$$J'_\lambda = T' + \lambda, \quad 0 < m = T''(b) \leq J''_\lambda.$$

M0 : b si $\lambda \leq \lambda_b$, a si $\lambda \geq \lambda_a$, sinon dichotomie sur l'unique racine intérieure.

$$\lambda_b = -T'(b) < \lambda_a = -T'(a).$$

Référence flottante et bornes numériques conditionnelles.

Réseau tanh à 49 paramètres

$$\theta = (w, b, v, d), \quad 16 + 16 + 16 + 1 = 49.$$

$$z = \frac{2(p - a)}{b - a} - 1, \quad \alpha_N = \frac{100}{9}.$$

$$h_i = \tanh(w_i z + b_i), \quad \hat{T} = d + \sum_i v_i h_i.$$

$$\hat{T}'(p) = \alpha_N \sum_i v_i w_i (1 - h_i^2).$$

$c_{\text{out}} = 0$, $s_{\text{out}} = 1$. Dérivée par rapport à p physique. L'architecture n'impose ni monotonie ni convexité.

Valeurs seules ou valeurs et dérivées

$$\mathcal{L}_1 = \frac{1}{n} \sum_j \frac{(\hat{T} - T)^2}{S_0^2}, \quad \mathcal{L}_2 = \mathcal{L}_1 + \frac{1}{n} \sum_j \frac{(\hat{T}' - T')^2}{S_1^2}.$$

$$S_0 = T(a) - T(b) \simeq 0.57295, \quad S_1 = -T'(a) \simeq 9.31369.$$

M1 apprend les valeurs. M2 ajoute les sensibilités. Coefficient différentiel 1, aucun facteur 1/2, aucune régularisation. Échelles fixes issues de l'oracle, sans estimation sur diagnostic. Gradients analytiques des 49 paramètres.

Protocole apparié et coût des labels

Condition	Sites	n_T	$n_{T'}$	Coût si $q_1 = 1$
M1_16	16	16	0	16
M2_16	16	16	16	32
M1_32	32	32	0	32

20 graines, mêmes paramètres initiaux par graine. Adam full-batch : 3000 updates, snapshot 300 secondaire.

$\eta = 0.001$, $\beta_1 = 0.9$, $\beta_2 = 0.999$, $\epsilon = 10^{-8}$ hors racine. Compteur et moments conservés.

257 sites diagnostiques disjoints. $q_1 = 1$ est conventionnel : même coût de labels ne signifie pas mêmes sites ou même temps.

Garanties classiques sous hypothèses

$$R \leq 2\varepsilon + \alpha_{\text{opt}}$$

Erreur uniforme ε et défaut global d'optimisation majorés. Une RMSE ne fournit pas ε .

$$|p - p^*| \leq r/m, \quad R \leq r^2/(2m).$$

r est le résidu KKT physique, avec les signes adaptés aux frontières.

Décision neuronale : meilleur des 1025 candidats, sans raffinement. Aucune convexité du réseau supposée.

Bornes de grille/M0 conditionnelles. Les erreurs flottantes totales restent non majorées.

Illustration : graine 20262001





Illustration : graine 20262001, étape 3000, 257 sites diagnostiques

Étape 3000, trois modèles sauvegardés, 257 sites. Pour cette graine, M2 réduit les RMSE mais son score décisionnel est légèrement plus élevé. Cette illustration n'est pas une moyenne.


Les vingt paires de scores décisionnels



Étape 3000, $n = 20$ graines appariées, toutes conservées
 S est une différence de coût contre M0 flottant ; unités sans dimension

$D = J_{\text{phys}}(\hat{p}) - J_{\text{phys}}(p_{\text{ref}})$. S est la moyenne des trois D intérieurs, sans clipping. Vingt initialisations, toutes conservées.

Gain moyen de M2 dans les deux contrastes




Étape 3000, $n = 20$ paires ; IC percentiles 95 %, $B = 2000$ tirages par blocs
M1_32 : égalité du coût de labels uniquement sous $q_1 = 1$

Différence moyenne	Estimation	IC 95 %
M2_16—M1_16	—0.01006	[—0.01460; —0.00557]
M2_16—M1_32	—0.00940	[—0.01390; —0.00503]

13 paires favorables sur 20 dans chaque comparaison. Gain moyen, sans gain garanti pour toute graine.

Erreur et mauvaise décision : panel principal



Panel principal : M1_16, étape 3000, $n = 20$ graines
 $\Delta\rho = 0.0068$, IC bootstrap 95 % $[-0.0568; 0.0791]$: inconclusif

M1_16 à 3000, vingt points. Deux associations positives. L'IC de $\Delta\rho$ inclut zéro : association supérieure des sensibilités inconclusive.

Bootstrap par blocs de graines

Statistique	Estimation	IC 95 %
ρ_{valeur}	0.9413	[0.8000; 0.9882]
ρ_{sens}	0.9481	[0.7925; 0.9958]
$\Delta\rho$	0.0068	[-0.0568; 0.0791]

$n = 20$, $B = 2000$: une matrice commune, graines tirées avec remise, tous les résultats du bloc conservés.

Rangs moyens pour égalités exactes. Variable constante : non défini. IC percentile interpolé, au moins 90 % de tirages définis.

Autres conditions, étape 300 et frontières : secondaires. Pas de pooling ou de garantie simultanée des IC.

Conclusions et limites

- M2 améliore le score décisionnel moyen dans les deux comparaisons prévues, dans ce benchmark.
- L'hypothèse d'une association supérieure des sensibilités reste inconclusive.
- Un seul cas scalaire sans bruit, vingt initialisations, référence flottante. Protocole après inspection du pilote.

Aucune nouveauté d'algorithme, causalité ou supériorité générale établie.

Une extension future : transfert à un second cas physique, avec coût des valeurs et dérivées explicitement mesuré. Elle reste non exécutée.

Sources et archives

- Czarnecki et al., *Sobolev Training for Neural Networks*, NIPS 2017.
- Yao et al., *Derivative-Informed Fourier Neural Operator: Universal Approximation and Applications to PDE-Constrained Optimization*, arXiv:2512.14086, 2025, révision 2026. Prépublication.
- Alexandrov et al., *A trust-region framework for managing the use of approximation models in optimization*, 1998.
- Elmachoub et Grigas, *Smart Predict, then Optimize*, Management Science, 2022.

Lecture bibliographique partielle ; références complètes dans le rapport.

Archives : résultats 3B/3C, paramètres, contextes et exports CSV. Aucun nouvel entraînement pour cette présentation.